

技術報告：多模態信用風險智能評估系統

作者：Joey Wu（巫佳樺） 日期：2026-05-12 版本：Demo v2（時序模態已升級至真實資料）

一、商業問題與動機

薄檔借款人的信用評估挑戰

傳統信用評分系統（如 FICO）依賴借款人的歷史還款紀錄、信用卡使用率、負債比等結構化數據。然而在台灣及東南亞市場，有相當比例的借款人屬於「薄檔」族群（thin-file borrowers）：剛出社會的年輕人、自營業者、或從未使用信用產品的族群。這些人缺乏傳統信用歷史，卻不代表信用風險高，傳統模型往往因資料缺失而拒絕他們的申請，造成金融排除（financial exclusion）。

在多元金融集團的貸款業務場景中，挑戰更為複雜：客戶資料不僅包含結構化的保單與收入資訊，也包含非結構化的申請書自述、核保備註、理賠溝通紀錄等多種形式的資料。壽險、產險、銀行、證券業務的客戶資料天然就是多模態的，但目前各業務線的資料都在各自的系統裡，從未被整合進信用決策。如何整合這些異質資料來源，建立一個比單一表格模型更全面的風險評估系統，是本專案試圖回答的核心問題。

為什麼單一 Tabular 模型不夠

XGBoost 在結構化信用資料上的表現已相當成熟，但它有三個根本限制：

第一，靜態快照問題。 XGBoost 接受的是某時間點的特徵聚合（如「過去兩年逾期次數」），無法捕捉借款人行為的時間動態。同樣的「逾期 2 次」，發生在三年前與發生在最近三個月，風險截然不同。

第二，獨立個體假設。 XGBoost 把每個借款人視為獨立樣本，忽略了借款人之間的社會關係。詐欺行為往往以群體形式出現——同一擔保人圈子、同一家企業的員工、同一仲介介紹的申請人——這些群聚風險在個體模型中完全不可見。

第三，文字資料浪費。 銀行每天收到的申請書、通話紀錄、備註欄位包含豐富的信用信號，傳統模型全部丟棄。

Multi-Modal 的商業價值

多模態系統的核心主張是：**每種資料型態捕捉的是借款人信用輪廓的不同面向**，而非冗餘資訊。

- **表格資料** 捕捉靜態財務快照（收入、負債比、歷史逾期）
- **時序資料** 捕捉動態行為趨勢（還款是否惡化、財務壓力是否加劇）
- **圖資料** 捕捉社群風險傳染（高風險群體的聚集與擴散）

- **文字資料** 捕捉申請人自述的意圖與一致性（申述與行為是否吻合）
-

二、資料來源與處理

2.1 表格資料：GiveMeSomeCredit

本專案使用 Kaggle 的 GiveMeSomeCredit 資料集作為表格模態的資料來源。原始資料集包含約 15 萬筆美國借款人紀錄，目標變數 `SeriousDlqin2yrs` 代表未來兩年內發生 90 天以上逾期，正例率約 6.7%。

本 Demo 的重要限制：本地使用的 `cs-training.csv` 為 1,200 筆樣本，正例率達 40.2%，與原始資料的分佈存在顯著差異。完整 150K 資料集的 XGBoost AUC 預期可達 0.85 以上（依公開 Benchmark 參考）。

清洗策略（共 8 步驟）：

1. 移除 Kaggle 匯出的無名索引欄
2. 將逾期欄位的哨兵碼 96 和 98 替換為 NaN（信用局的「不適用」編碼，非真實逾期次數）
3. 刪除 `age = 0` 的不可能值（共 1 筆）
4. 將 `RevolvingUtilizationOfUnsecuredLines` 上限裁剪至 1.0
5. 將 `DebtRatio` 上限裁剪至 99 百分位
6. 以中位數填補 `MonthlyIncome` 的約 20% 缺失值（分佈右偏，不適用均值）
7. 以 0 填補 `NumberOfDependents` 的約 2.5% 缺失值
8. 以各欄中位數填補哨兵碼清除後的 NaN

特徵工程新增六個衍生特徵： `income_per_dependent`、`total_past_due`、`has_any_delinquency`、`credit_line_utilization`、`debt_to_income_log`、`age_bucket`。

2.2 時序資料：Lending Club（真實資料） v2 升級

v1 的問題：合成資料缺乏序列相關性

v1 版本使用 `create_synthetic_time_series()` 為每位借款人生成 12 個月序列，`is_late_t` 基於 Bernoulli 獨立抽樣。主要限制：每個月的逾期事件是獨立的，缺乏真實逾期的連環效應（serial correlation）——真實世界的違約往往是連環發生的，這個月逾期後下個月繼續逾期的機率顯著更高。

v2 升級：Lending Club 真實月度還款紀錄

v2 使用 Lending Club 公開貸款資料集 (`loan.csv`)，包含 100,000 筆真實借款人紀錄，正例率 3.4%，與真實信用市場的違約率分佈吻合。

資料處理流程 (`src/data/lending_club_timeseries.py`)：

- 以 50K 行分塊讀取 1.2GB 原始檔案，避免記憶體不足
- 使用攤銷公式重建月度餘額軌跡：
$$\text{balance_t} = P \cdot (1+r)^t - \text{installment} \cdot ((1+r)^t - 1) / r$$
- 逾期時間點依據 `mths_since_last_delinq` 推算，逾期窗口設為 6 個月
- 四個特徵 (`utilization`、`payment_ratio`、`is_late`、`balance`) 均由資料自然正規化至 [0,1]
- 篩選條件：`elapsed >= 12`，確保每位借款人有完整 12 個月歷史

嚴格時間切割（防止 Data Leakage）：

訓練輸入使用前 10 個月 (`sequences[:, :10, :]`)，標籤定義為第 11-12 個月是否出現逾期。此設計模擬真實早期預警場景：用過去行為預測未來違約。

Data Leakage 偵測與修正：

初版訓練 AUC = 1.0，診斷為 label leakage——`loan_status` 同時出現在特徵和標籤的推導中。修正措施：

1. 完全移除 `loan_status` 欄位，不從此欄位推導任何特徵或標籤
2. 標籤僅從序列自身推導：`max(seq[10, IS_LATE_IDX], seq[11, IS_LATE_IDX])`
3. 新增迴歸測試 `test_no_perfect_input_to_label_leakage`：確認輸入第 10 個月的 `is_late` 與標籤之間有 >5% 的不一致率

修正後 AUC = 0.9733，符合預期。

序列相關性驗證：

族群	人數	輸入窗口（月 1-10）中有逾期紀錄
違約者 (label=1)	3,431	90.5%
正常者 (label=0)	96,569	8.9%

90% 的違約者在違約發生前 1-5 個月已出現逾期前兆，驗證了「違約不是突然發生的，它有連環效應」的業務假設。這是 LSTM 早期預警系統的核心價值所在。

2.3 圖資料：合成借款人相似圖

對 5 個正規化特徵計算 Cosine Similarity，閾值 0.85 連邊，每個節點最多 10 個鄰居，雙向邊。圖統計：840 節點，10,408 條邊，平均度數 12.39，密度 0.0148（稀疏圖），單一連通分量。

主要限制：邊代表「特徵相似的借款人群」，不代表真實的擔保人或共同借款人關係。升級路徑是從 CRM 系統拉取真實的共同借款人、擔保人、推薦人關係建圖，賦予邊真實的業務語意。

2.4 文字資料：合成貸款申請描述

以 Faker 與模板語句生成 5,000 筆貸款申請描述，依借款目的（債務整合、醫療、房屋修繕等）分類。文字的語意變化僅來自模板替換，sentence-BERT 的 embedding 因模板相似而聚集，文字模態在合成環境下的區辨能力有限。升級路徑是換成真實申請書描述並使用 FinBERT。

三、模型架構

3.1 四個 Encoder 的設計選擇

XGBoost（表格 Encoder）

使用 `scale_pos_weight = 負例數/正例數` 處理類別不平衡。以 `model.apply()` 取得每棵樹的葉節點索引，透過 `nn.Embedding` 轉換為 32 維密集向量後平均池化。葉節點 Embedding 的優點在於它已整合了 XGBoost 學習到的非線性特徵交互——落在同一葉節點的借款人在信用行為上被模型視為等價。

Bi-LSTM（時序 Encoder）

v2 輸入形狀 (batch, 10, 4) (v1 為 12 個月，v2 為前 10 個月以配合時間切割)。兩層 LSTM (hidden_size=64, dropout=0.2)，取最後一個隱藏狀態 (last hidden state) 而非 mean pooling，再透過線性層投影至 32 維。

取 last hidden state 的理由：LSTM 的 gate 機制已在 forward pass 中決定哪些時間步的資訊值得保留，這個摘要比均等對待所有時間步的 mean pooling 更能保留序列的因果結構。

選 Bi-LSTM 不選 Transformer 的理由：序列只有 10-12 步，Transformer 的優勢在長序列的長距離依賴，10 步的情況下多出來的參數是成本而非收益。

GraphSAGE（圖 Encoder）

兩層 SAGEConv (input→64→32)。選 SAGEConv 而非 GCNConv 的關鍵原因是 Inductive Learning：SAGEConv 學習的是鄰域聚合函數，新借款人無需重新訓練整個圖模型即可產生 Embedding，這在每日有新申請人的生產環境中至關重要。2 層覆蓋 2-hop 鄰域，在信用風險情境中等同於「借款人的借款人」的群聚傳染信號。此演算法出自 Stanford CS224W 研究室 (Hamilton et al., 2017)。

sentence-BERT (文字 Encoder)

凍結 `all-MiniLM-L6-v2` 的全部 2,200 萬參數，僅訓練 384→32 的線性投影頭 (12,320 個參數)。

凍結的理由：5,000 筆合成資料不足以更新 2,200 萬個參數，fine-tuning 只會使 Transformer 過擬合模板語句的表面特徵。凍結保留 Transformer 從 10 億句子對訓練得到的通用語意理解，投影頭只學習哪個語意方向跟信用違約有關。

選 `all-MiniLM-L6-v2` 不選 `bert-base` 的理由：知識蒸餾版本，2,200 萬參數 (bert-base 為 1.1 億)，CPU 推論速度快約 5 倍，適合無 GPU 的 Demo 環境。

3.2 Late Fusion 設計

四個 Encoder 各自輸出 (batch, 32) 的 Embedding，拼接為 (batch, 128) 後進入三層 MLP (128→64→32→1)，dropout=0.3，輸出原始 logit，訓練時使用 `BCEWithLogitsLoss`。

選擇 Late Fusion 而非 Early Fusion 的核心原因：每個模態的特徵空間與最佳歸納偏置完全不同——結構化數值、時間序列、圖拓撲、文字語意無法在輸入層合理地統一表示。Late Fusion 保留各 Encoder 的模態專屬學習能力，並支援模態缺失的優雅降級。

選擇 Concat 而非 Attention 加權融合：在當前訓練規模下，學習 per-sample 的模態信任權重會導致過擬合；Attention 融合是真實資料規模足夠後的升級路徑。

3.3 訓練流程

各模態按順序獨立訓練：XGBoost → LSTM → GNN → Text Embedding → Fusion。訓練產物以 `.pt` / `.pkl` 格式儲存於 `data/processed/`。Fusion 模型在訓練時輸入預計算好的 Embedding，不做端對端梯度反傳 (XGBoost 在 PyTorch autograd 圖之外)。

v2 新增 `--data_source [synthetic|lending_club]` flag，切換時序資料來源時無需修改其他程式碼，各模態的訓練產物分別儲存 (`lstm_encoder.pt` vs `lstm_encoder_lc.pt`), (`fusion_model.pt` vs `fusion_model_lc.pt`)。

四、實驗結果

4.1 各模組驗證指標

模組	資料	Val AUC	說明
XGBoost	真實 (1,200筆, 40% 正例率)	0.67	樣本小、分佈失真；完整資料集預期 0.85+
Bi-LSTM	合成 (Bernoulli, v1)	0.72	每月獨立抽樣，無序列相關——已升級
Bi-LSTM	真實 (Lending Club 100K, v2)	0.97	序列相關性驗證通過；高 AUC 反映真實連環效應
GraphSAGE	合成相似圖	0.74	反映 Cosine 圖結構，非真實信用傳染
Late Fusion	混合 (LC 時序 + 合成其他)	0.74	四模態整合後的系統級預測能力
PR-AUC	混合	0.64	正例率 3.4% 下的精準率-召回率綜合指標
F1@0.5	混合	0.64	閾值 0.5 下的調和平均數

關於 LSTM AUC 0.97 的誠實說明：

Sanity check 顯示，90.5% 的違約借款人在輸入窗口（月 1-10）內已有 `is_late=1` 的紀錄。LSTM 學到的核心規則是「過去有逾期 → 未來更可能逾期」——這是真實信用行為的正確規律，也是早期預警系統的基礎假設，但並非複雜的時序模式學習。`payment_ratio` 和 `balance` 曲線對預測的邊際貢獻有限。

此結果反映了 Lending Club 資料的內在特性，而非 LSTM 模型的過度複雜化。在真實生產環境中，這種序列相關性正是金融機構建立早期預警系統的核心依據。

4.2 合成 vs 真實時序資料對比

指標	合成資料 (v1)	真實資料 (v2)
資料來源	Bernoulli 獨立抽樣	Lending Club 真實還款紀錄
序列相關性	✗ 無	✓ 驗證通過
樣本數	1,200	100,000

指標	合成資料 (v1)	真實資料 (v2)
正例率	40.2%	3.4% (真實分佈)
Val AUC	0.72	0.97
Data Leakage	無	初版有, 已修正

4.3 圖模型統計

指標	數值
num_nodes	840
num_edges	10,408
avg_degree	12.39
density	0.0148
is_connected	True

4.4 SHAP Top Features (XGBoost)

SHAP 分析顯示最重要的特徵為：循環信用使用率 (`RevolvingUtilizationOfUnsecuredLines`)、年齡區段 (`age_bucket`)、負債比率 (`DebtRatio`)。特徵工程設計的 `total_past_due` 進入 Top 5，驗證了聚合設計的有效性。循環信用使用率高（紅點）一致地把風險分數推高，與信貸員直覺完全一致。

五、可解釋性與合規設計

5.1 雙層 SHAP 鏈路

本系統實現兩層 SHAP 解釋：

特徵層 (XGBoost SHAP)：指出「哪個欄位、推高了多少分」，例如「申請人 90 天逾期次數為 2 次，使風險分數上升 0.12」。精確到欄位名稱、方向、數值。

模態層 (Fusion SHAP)：指出「哪個 Encoder 對最終預測貢獻最大」，幫助信貸員理解是時序行為還是社群位置主導了這次判定。

5.2 GenAI 授信報告

Claude API 的角色是翻譯者，而非決策者。系統將雙層 SHAP 輸出作為 Prompt 的強制上下文，限制模型只能基於已計算的 SHAP 值撰寫報告，不能引入自由推測。這是防止 LLM 幻覺的核心護欄——信貸報告中出現不實資訊的法律後果遠高於其他場景。

5.3 合規設計

Adverse Action Notice：SHAP 輸出可直接填入不利行動通知，符合台灣金融消費者保護法要求的具體拒貸理由。

Fairness Audit：年齡、家庭人數可能是敏感族群的代理變數，需定期分群確認核准率與 SHAP Top 特徵是否一致。

Audit Trail：每筆決策記錄 `model_version`、`shap_top_features`、`override_reason`、`reviewer_id`，法規單位調閱時可在 30 秒內重現完整決策脈絡。

5.4 風險分層

風險等級	機率範圍	建議行動
低風險	$P < 0.3$	快速審核通過
中風險	$0.3 \leq P < 0.6$	人工複審，補件確認
高風險	$P \geq 0.6$	拒絕或要求擔保

閾值為可調整的業務參數，非模型超參數，可透過 Precision-Recall 曲線依業務目標校準。

六、限制與未來工作

6.1 已完成的升級

- ✔ **時序模態：**從 Bernoulli 合成資料升級至 Lending Club 100K 真實月度還款紀錄；序列相關性統計驗證通過；嚴格時間切割防止 data leakage；AUC 從 0.72 提升至 0.97

6.2 仍需真實資料的模態

圖模態：目前的邊代表特徵相似，不代表真實擔保關係。升級路徑是從 CRM 拉取共同借款人、擔保人、推薦人關係建圖，使 GraphSAGE 能偵測真實群聚詐欺。

文字模態： 模板生成的文字語意變化不足， **sentence-BERT** 的區辨能力被低估。升級路徑是換成真實申請書描述，並使用 **FinBERT** 或金融領域微調模型。

表格模態： GiveMeSomeCredit 是美國消費者資料，基礎違約率與特徵分佈與台灣保險客群不同，需在本地資料分佈上重新校準。

6.3 架構層面的改進方向

- **Attention 融合：** 在樣本量足夠時，以 per-sample 的模態信任權重替代固定 concat
- **GAT 替代 GraphSAGE：** Graph Attention Network 提供 case-level 的 GNN 可解釋性
- **時序 Markov Chain 合成：** 在無真實資料時，以 Markov Chain 狀態轉移矩陣替代 Bernoulli 獨立抽樣，更真實地模擬連環違約
- **端對端訓練：** 使用可微分的樹近似（如 TabNet）替代 XGBoost，讓整個 pipeline 在同一梯度流中訓練

七、技術棧總覽

分類	技術	用途
表格模型	XGBoost	表格 Encoder + Leaf Embedding
深度學習框架	PyTorch	LSTM、Fusion MLP 訓練
圖神經網路	PyTorch Geometric (PyG)	GraphSAGE 節點 Embedding
自然語言處理	sentence-transformers	凍結 all-MiniLM-L6-v2
可解釋性	SHAP	特徵貢獻度分析與視覺化
實驗追蹤	MLflow	AUC、Loss 曲線記錄
前端介面	Streamlit	互動式信貸評估 Dashboard
業務分析	Power BI	主管儀表板、客群分析
生成式 AI	Anthropic Claude API	SHAP 驅動的中文信貸報告生成
時序資料	Lending Club (真實)	100K 真實月度還款序列
表格資料	GiveMeSomeCredit (真實)	1,200 筆信用特徵 (Demo 樣本)
資料處理	pandas、scikit-learn	清洗、特徵工程、評估指標

本報告記錄 **Demo v2** 的完整設計決策與實驗結果。**v2** 核心升級為時序模態從合成資料遷移至 **Lending Club** 真實月度還款紀錄，並完成 **Data Leakage** 診斷與修正。所有程式碼版本控制於 **git**。